DEEP LEARNING PER LA MATEMATICA SIMBOLICA

Elia Mercatanti

Relatore: Donatella Merlini

Università degli Studi di Firenze Scuola di Scienze Matematiche, Fisiche e Naturali Corso di Laurea in Informatica

Anno Accademico 2020-2021





Motivazioni

Successo delle reti neurali negli ultimi anni

- Sono lo stato dell'arte in un ampia varietà di problemi.
- Sono estremamente efficaci nel pattern recognition.
- Limitato successo nel calcolo simbolico, anche in compiti semplici come la moltiplicazione di interi.
- Grande successo su compiti del *Natural Language Processing* e sulle traduzioni: problemi di manipolazione simbolica.

Applicare il deep learning al calcolo simbolico

- Anche le persone hanno difficoltà nell'eseguire complessi calcoli simbolici.
- Il pattern recognition può essere utile per l'integrazione.
- Gli approcci precedenti hanno quasi sempre considerato dataset molto piccoli.



Intuizione di Base

Architetture per la Traduzione Automatica

- Lavorano su frasi considerate come sequenze di tokens.
- Non hanno bisogno di specifiche informazioni sul problema.
- Usano enormi dataset.

Matematica Simbolica

- Può essere considerata come un linguaggio.
- Possono essere generati grandi dataset.
- Risolvere un problema equivale a "tradurre" quest'ultimo nella sua soluzione.

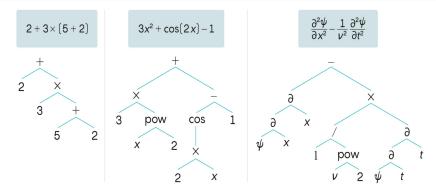
Deep Learning per la Matematica Simbolica

Cosa è stato fatto:

- Sono state usate tecniche per il Natural Language Processing sui problemi di matematica simbolica.
- Su due problemi: integrazioni, equazioni differenziali.
- Usando modelli Sequence to Sequence (Seq2Seq), in particolare il Transformer.
- Problemi e soluzioni rappresentati tramite sequenze.
- Generando grandi dataset di problemi e soluzioni.
- Addestrando vari modelli per "tradurre" i problemi nelle loro soluzioni.
- Valutando le loro prestazioni, anche su alcuni casi particolari.
- Confronto con framework di calcolo simbolico classici (Mathematica, Maple e Matlab)



Espressioni Matematiche in Forma di Alberi



Vantaggi:

- Non ambiguità nell'ordine delle operazioni.
- Rimozione di simboli non significativi (parentesi, spazi, ecc.).
- Ad ogni espressione diversa corrisponde un albero diverso.
- Corrispondenza biunivoca tra espressioni ed alberi.



Dagli Alberi alle Sequenze

Sequenza in Notazione Prefissa:

$$[+ \times 3 \text{ pow } x 2 - \cos \times 2 x 1]$$

Vantaggi sull'uso della notazione prefissa:

- Trasforma facilmente gli alberi in sequenze.
- Garantisce rappresentazione biunivoca tra sequenze ed alberi.
- Non necessita di parentesi finché ogni operatore ha un numero fisso di operandi.



Generare Espressioni Matematiche Casuali

Sono stati generati grandi dataset di espressioni matematiche casuali per i due problemi scelti, sfruttando gli alberi.

 Per ogni tipo di problema viene impiegata una strategia diversa.

Per generare un singolo problema o una soluzione casuale:

- Viene generato un albero unario-binario casuale.
- Per ogni nodo interno vengono selezionati operatori casuali.
- Ogni nodo foglia viene sostituito con una costante, un intero, o una variabile casuale.
- Ogni forma di albero ha la possibilità di essere generata con la stessa probabilità.



Integrazioni - Forward Generation (FWD)

Strategia del Generatore:

- Viene generata un funzione casuale f.
- Viene calcolata la sua primitiva F con un framework di matematica simbolica (SymPy).
- La coppia (f, F) viene aggiunta al dataset.

Caratteristiche:

- Richiede una framework di calcolo simbolico esterno.
- Limitato alle funzioni che il framework può integrare.
- Lento dal punto di vista computazionale.
- Tende a generare problemi corti con soluzioni lunghe.



Integrazioni - Backward Generation (BWD)

Strategia del Generatore:

- Viene generata un funzione casuale f.
- Viene calcolata la sua derivata f' con un framework di matematica simbolica (SymPy).
- La coppia (f', f) viene aggiunta al dataset.

Caratteristiche:

- La differenziazione è sempre possibile ed estremamente veloce.
- Non dipende da un sistema di integrazione simbolica esterno.
- Efficiente dal punto di vista computazionale.
- Tende a generare problemi lunghi con soluzioni corte.
- Improbabile che venga generato l'integrale di funzioni semplici.



Integrazioni - Backward con Integrazione per Parti (IBP)

Strategia del Generatore:

- Vengono generate due funzione casuali F e G.
- Vengono calcolate la loro derivata f e g con un framework di matematica simbolica (SymPy).
- Se f * G è presente nel dataset, viene calcolato l'integrale di F * g con:

$$\int Fg = FG - \int fG$$

Il nuovo integrale scoperto viene aggiunto al dataset.

Caratteristiche:

- Può generare gli integrali di funzioni semplici.
- Lento dal punto di vista computazionale.

